

Proyecto 1: EDA + Baseline

Lab de arranque: martes 1 de septiembre · Entrega: viernes 11 de septiembre, 23:59 · 10 pts

Qué es

Un notebook sobre un dataset **real** elegido por usted, que responda una pregunta clara. Tres partes:

1. **EDA honesto**: forma, tipos, faltantes con su mecanismo (MCAR/MAR/MNAR), outliers, distribuciones y relaciones. Hallazgos escritos, no galería de gráficas.
2. **Feature engineering justificado**: encodings, escalamiento y variables derivadas, cada decisión con su razón en una frase.
3. **Un baseline**: regresión lineal o k-NN, con partición train/test y una métrica adecuada. El **baseline trivial** (predecir la media o la clase mayoritaria) es obligatorio como punto de comparación: sin él, un número no significa nada.

Lo que **no** se pide: modelos avanzados ni tuning exhaustivo. El objetivo no es el accuracy más alto del salón, sino demostrar que entendió sus datos antes de modelarlos.

El dataset

- Real y de su elección (público o propio). El catálogo del curso (Datasets/datasets.md) tiene opciones verificadas si no tiene uno en mente.
- Con **procedencia documentada**: fuente, URL, fecha de descarga y licencia, en el notebook (la ficha de la sesión 4).
- Con suficiente contenido para que la pregunta tenga sentido; si duda del suyo, consúltelo en el lab o por el canal del curso.

Entrega

- Trabajo individual.
- El notebook de la sesión 12 (Lab) trae la estructura ya creada: pregunta y contexto, los datos, primer barrido, calidad de datos, EDA, features, baseline, conclusiones y límites. Trabajar sobre esa plantilla.

- Entregar el notebook **ejecutado de arriba a abajo** (Restart & Run All) más el dataset o el enlace para descargarlo, por el canal indicado en clase, a más tardar el **viernes 11 de septiembre a las 23:59**.
- **AI**: permitida como asistente. Si la usó, incluir la **bitácora de colaboración**: qué preguntó, en qué ayudó, qué decidió usted. Entregas con AI y sin bitácora se penalizan.

Rúbrica (10 pts)

Criterio	Pts	Qué se busca
Pregunta y datos	2	Pregunta clara desde la primera celda; procedencia completa del dataset
EDA	3	Hallazgos numerados y escritos; cada gráfica con su conclusión
Features	2	Cada decisión justificada; sin leakage
Baseline	2	Partición correcta, baseline trivial, métrica adecuada al problema
Límites	1	Un párrafo honesto de qué no puede concluirse con estos datos

Entre EDA y features hay 5 de los 10 puntos: el modelo es la parte más chica del proyecto, y también la más fácil.

Checklist antes de entregar

1. ¿Se lee en la primera celda **qué pregunta** responde el proyecto?
2. ¿Está documentado de dónde salieron los datos, cuándo y bajo qué licencia?
3. ¿Cada gráfica tiene una conclusión escrita debajo? Si no la tiene, sobra.
4. ¿Cada feature nuevo tiene una frase que explique por qué existe?
5. ¿El escalamiento y los encodings se ajustaron **solo** con el train?
6. ¿Hay un párrafo final que diga qué *no* se puede concluir?

Errores que se penalizan

- **Leakage:** escalar o imputar con todo el dataset antes de partir, o usar una variable que no existiría al momento de predecir.
- **Gráficas sin pregunta:** veinte histogramas seguidos y ninguna conclusión.
- **Conclusiones sin soporte:** afirmar causalidad desde una correlación.
- **Faltantes borrados en silencio:** un `dropna()` que se lleva el 40 % de las filas sin comentario.
- **Métrica desalineada:** accuracy sobre clases 95/5, o RMSE sin comparar contra el baseline trivial.